



Proceso de Minería de Datos

Dataset: World University Rankings - 2023

Marchena Ana, Monsalve Carlos, Pérez Juan

Universidad Central de Venezuela

12 de Marzo de 2026

Selección de Metodología

Para el desarrollo de este proyecto de Minería de Datos, se ha seleccionado el modelo **CRISP-DM** debido a su enfoque estructurado y sus múltiples ventajas operativas:

- **Naturaleza Iterativa:** Permite retroceder entre fases al detectar anomalías, ideal para refinar la limpieza de datos realizada.
- **Orientación al Negocio:** Garantiza que cada paso técnico esté alineado con los objetivos de análisis del ranking universitario.
- **Control de Calidad:** Facilita el diagnóstico y corrección de inconsistencias (como los rangos y valores nulos) antes de la fase de modelado.

Tabla de Contenido

- Selección de metodología
- ① Entendimiento del Negocio
- ② Entendimiento de los Datos
- ③ Preparación de los datos
- ④ Análisis Exploratorio
- ⑤ Evaluación y despliegue

Entendimiento del Negocio

Objetivo Principal:

- Analizar el rendimiento académico y la diversidad universitaria a nivel global.

Objetivos Específicos:

- Identificar factores que influyen en el **puntaje global**.
- Explorar patrones y relaciones entre variables institucionales.

Pregunta de Investigación

¿Cómo influyen variables como el porcentaje de estudiantes internacionales o la proporción de género en el puntaje global?

Entendimiento de los Datos

- **Dataset:** Consiste en el *World University Rankings 2023*, que evalúa 1799 universidades de 104 países bajo 13 indicadores clave..
- **Dimensión:** 2341 registros y 13 variables técnicas.
- **Fuente:** World University Rankings 2023.

Rank	University Name	...	Ratio F:M	Overall
1	University of Oxford	...	48 : 52	96.4
2	Harvard University	...	50 : 50	95.2
501–600	University of Sharjah	...	68 : 32	42.1–44.8
Reporter	Abubakar Tafawa Balewa	...	NaN	NaN

Entendimiento de los Datos

Inspección y Diagnóstico:

- **Inconsistencia de Formato:** La columna *Rank* mezcla valores numéricos con rangos y etiquetas de texto (“Reporter”).
- **Vacíos Estructurales:** Registros con *NaN* en el nombre de la institución (identificador esencial irre recuperable).
- **Datos Faltantes:** Campos de ubicación vacíos que comprometen el análisis geográfico.

Conclusión de la fase

Se requiere un proceso riguroso de limpieza y transformación para asegurar la confiabilidad del modelo final.

Preparación de los datos: Estandarización del Ranking

1. Tratamiento de la variable *University Rank*:

- **Problema:** Falta de uniformidad en los registros (mezcla de números enteros, rangos de texto y símbolos).
- **Solución aplicada:**
 - **Estandarización:** Unificación de valores faltantes o irrelevantes bajo la etiqueta '*Unknown*'.
 - **Transformación numérica:** Conversión de rangos a valores únicos mediante la extracción del *límite inferior*.

Ejemplo de transformación

"501–600" → **501** | "Reporter" → **Unknown**

Preparación de los datos: Integridad de Registros

2. Tratamiento de Identificadores Faltantes:

- **Problema:** Registros con valor *NaN* en la columna Name of University.
- **Solución aplicada:**
 - **Filtrado estricto:** Eliminación de toda fila que no posea un identificador claro.
 - **Resultado:** Aseguramiento de que cada entrada en el modelo final corresponda a una institución verificable.

Criterio de Exclusión

Si Name of University = *null* → **Eliminar Registro**

Preparación de los datos: Normalización Geográfica

3. Tratamiento de Valores Nulos en Ubicación:

- **Problema:** Campos nulos en la variable Location.
- **Impacto:** Dificulta la segmentación geográfica y los análisis comparativos por país o región.
- **Solución aplicada:**
 - **Imputación categórica:** Reemplazo de valores nulos por la etiqueta 'Unknown'.
 - **Estandarización:** Uniformidad para evitar errores en agrupaciones espaciales.

Ejemplo de imputación geográfica

Valores vacíos (NaN) → 'Unknown'

Preparación de los datos: Tratamiento de Población Estudiantil

4. Limpieza y Refinamiento de *No. of Students*:

- **Problema de Tipado:** Valores almacenados como texto.
- **Detección de Anomalías:** Presencia de registros con población estudiantil excesivamente baja.
- **Solución en dos fases:**
 - ① **Casting:** Conversión de cadenas de texto a números enteros.
 - ② **Imputación representativa:** Reemplazo de valores atípicos utilizando el **promedio de estudiantes por país**.

Ejemplo de transformación e imputación

“20,965” (Texto) → **20965** (Integer)

Univ. Atípica (e.g. 5 est.) → **Promedio País** (e.g. 12400)

Preparación de los datos: Segmentación de Variables

5. Tratamiento del ratio *Female:Male*:

- **Problema:** Proporción de género almacenada como una cadena de texto única (ej. "48 : 52").
- **Solución aplicada:**
 - **Parsing / Splitting:** División de la columna original en dos métricas independientes.
 - **Limpieza:** Eliminación del delimitador (":") y conversión de los valores a formato numérico (*float*).

Ejemplo de transformación de columnas

Entrada (F:M)		Salida (F M)
"48 : 52"	→	48.0 52.0

Preparación de los datos: Cuantificación del Desempeño

6. Normalización del *Overall Score*:

- **Limitación:** Los rangos de texto impiden el procesamiento por algoritmos de regresión o correlación.
- **Solución:** Transformación de rangos en su **valor promedio** aritmético (Marca de Clase) para obtener una variable continua.

Ejemplo de transformación numérica

Rango: "42.1 – 44.8" → **Promedio:** 43.45

Estado Final de los Datos

Tras estas 6 etapas, el dataset es un conjunto **limpio, tipado y listo** para la fase de modelado.

Análisis Exploratorio: Variables de Interés

Este dataset analiza universidades a nivel global según diferentes métricas de desempeño académico e internacionalización.



- **Ranking:** Posicionamiento de la universidad.
- **Puntaje Global:** Puntaje general atribuido a dicha universidad.
- **Puntajes por dimensiones:** Teaching, Research, etc. .
- **Variables de diversidad:** International Student, Female:Male Ratio.
- **Tamaño institucional:** No of student, Student per staff.

Pregunta de Investigación

¿Cómo influyen variables como el porcentaje de estudiantes internacionales o la proporción de género en el puntaje global?


Análisis Exploratorio: Métricas

1. Histograma y Boxplot para "Overall Score" o Puntaje Global



Análisis Exploratorio: Métricas

2. Heatmap o mapa de calor para correlacion de variables



Análisis Exploratorio: Métricas

3. Analizando el mapa de calor de la fila "Overall Score"

Variables	Correlación
Research Score	0.87
Citations Score	0.85
Teaching Score	0.81
International Outlook	0.65
International Student	0.56
Industry Income	0.45
No of student	0.01
Student per staff	-0.03


Análisis Exploratorio: Métricas

4. Scatter plot "Research Score" vs "OverAll Score"




Análisis Exploratorio: Métricas

4.1. Scatter plot con linea de regresion




Análisis Exploratorio: Métricas

5. Scatter plot International Student vs OverAll Score




Análisis Exploratorio: Métricas

6. Distribución de Estudiantes Internacionales




Análisis Exploratorio: Métricas

7. Top 10 países con mejor OverAll Score promedio



Análisis Exploratorio: Metricas

8. Top 5 universidades con porcentaje de Estudiantes Femeninos y Masculinos



Evaluación y Despliegue

Teniendo en cuenta que la regresion lineal se toman las variables numericas, creamos una variable para trabajar sobre ella usando los datos

```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

X = df_model[['Teaching Score',
                'Research Score',
                'Citations Score',
                'Industry Income Score',
                'International Outlook Score',
                'International Student']]

y = df_model['OverAll Score']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=5200)

model = LinearRegression()
model.fit(X_train, y_train)


y_pred = model.predict(X_test)

print("R2:", r2_score(y_test, y_pred))
print("MSE:", mean_squared_error(y_test, y_pred))

*** R2: 0.992283862683178
    MSE: 2.277283289722967
```



Evaluación y Despliegue

Verificando los resultados con graficas.



Evaluación y Despliegue

Mejorando las graficas.



Muchas Gracias!!